# Analyzing the Impact of Dropbox Content Sharing on an Academic Network

Glauber Gonçalves\*, Idilio Drago<sup>†</sup>, Ana Paula Couto da Silva\*, Alex Borges Vieira<sup>‡</sup>, Jussara M. Almeida\*

\*Department of Computer Science Universidade Federal de Minas Gerais, Brazil {ggoncalves; ana.coutosilva; jussara}@dcc.ufmg.br

†Department of Electronics and Telecommunications Politecnico di Torino, Italy idilio.drago@polito.it

<sup>‡</sup>Department of Computer Science Universidade Federal de Juiz de Fora, Brazil alex.borges@ufjf.edu.br

#### Abstract

Cloud storage services (e.g., Dropbox) are a popular means for sharing content and performing collaborative work. Yet, content sharing via cloud might result in bandwidth wastage when repetitive data is downloaded by different users in the same network domain. This paper first characterizes sharing patterns in Dropbox by analyzing data collected from a campus network for 4 months. We identify that the volume of data sharing in such homogeneous environment is reasonably high. Next, we use the characterization results to implement a synthetic workload generator that allows us to test alternatives for the Dropbox synchronization protocol. We then propose a synchronization architecture that includes network caches to temporarily hold user updates. Our evaluation of the proposed solution indicates that, even with a small cache, it is possible to achieve almost the maximum possible reduction of downloads from remote servers, thus benefiting storage providers, end users and the Internet.

#### Resumo

Serviços de armazenamento na nuvem (e.g., Dropbox) são meios populares de compartilhamento de conteúdo e realização de trabalho colaborativo. Contudo, o compartilhamento nas nuvens pode levar a desperdício de largura de banda quando o mesmo conteúdo é recuperado de servidores remotos por múltiplos usuários em um mesmo domínio de rede. Este artigo apresenta uma caracterização dos padrões de compartilhamento no Dropbox a partir de dados de tráfego coletados de um campus universitário durante 4 meses. Identificamos que o volume compartilhado via Dropbox é razoavelmente alto. Em seguida, utilizamos os resultados da caracterização para desenvolver um gerador de cargas sintéticas que permite avaliar alterações no protocolo de sincronização do Dropbox. Propomos então uma arquitetura de sincronização que inclui caches para temporariamente armazenar as atualizações dos usuários. Nossos resultados indicam que, mesmo com um cache pequeno, é possível evitar praticamente todos os downloads redundantes, o que beneficia provedores do serviço de armazenamento, usuários e a Internet.

#### Keywords

Cloud storage; Dropbox; content sharing; cache

## I. INTRODUÇÃO

Os serviços de armazenamento pessoal em nuvem (*Personal Cloud Storage*) estão cada dia mais populares, tanto entre usuários domésticos quanto corporativos. Isso pode ser observado, por exemplo, pela crescente popularidade de termos como "Dropbox", "iCloud" e "Google Drive" em consultas ao principal serviço de buscas da Internet (i.e., Google)<sup>1</sup>. Serviços de armazenamento nas nuvens oferecem diversas vantagens a seus usuários. Esses podem eliminar praticamente toda a sua infraestrutura de armazenamento, confiando somente em servidores remotos. Além disso, a migração para esse tipo de serviço não requer grandes investimentos. Usuários passam a contar com replicação (i.e., *backup*) e compartilhamento de dados via Internet de forma transparente e flexível.

This work is supported by the INWeb (MCT/CNPq grant 57.3871/2008-6), and by the authors grants from CNPq and FAPEMIG  $^1$ http://www.google.com/trends



Serviços de *Personal Cloud Storage* também vêm atraindo a atenção de pesquisadores, principalmente pelo impacto gerado no tráfego da Internet e em redes locais [1], [2]. Dentre os serviços existentes, o Dropbox vem sendo um dos mais estudados, em particular por sua grande inserção em ambientes acadêmicos. Em [3] foi observado um volume significativo de tráfego relacionado ao Dropbox em campi universitários. Tal volume foi comparado ao tráfego de serviços tradicionais da Internet, como o YouTube.

O compartilhamento de arquivos no Dropbox pode levar a desperdício de banda quando um mesmo conteúdo é recuperado dos servidores remotos pelos vários usuários que o compartilham. O Dropbox busca otimizar a utilização da rede por meio de vários mecanismos em seu cliente, incluindo compressão de dados, de-duplicação e agrupamento de transferências (i.e., bundling) [4]. Porém, embora esses mecanismos sejam eficientes em reduzir o tráfego particularmente das transferências dos clientes para a nuvem (i.e., upload), eles tem um efeito limitado na eliminação das redundâncias geradas pelo compartilhamento de conteúdo, que aparecem no download de dados. De fato, evidências [3] mostram que o volume de download é aproximadamente duas vezes superior ao de upload em redes acadêmicas.

Um dos principais mecanismos do Dropbox para minimizar essas redundâncias é o protocolo LAN sync². Por esse mecanismo, arquivos compartilhados entre dispositivos em uma mesma (sub-)rede (i.e., em um mesmo perímetro de *broadcast*) são atualizados sem que cada um dos dispositivos recupere os arquivos da nuvem. Todavia, esse mecanismo não explora todo o potencial de redução do uso da rede. Isso porque grande parte das redes, como as redes acadêmicas, são compostas por várias sub-redes. Os dispositivos em sub-redes distintas não se beneficiam do protocolo LAN sync. Logo, usuários de um mesmo domínio (e.g., uma universidade) que compartilham conteúdo, mas cujos dispositivos estejam em sub-redes diferentes, devem recuperar o (mesmo) conteúdo diretamente da nuvem, gerando tráfego duplicado e desperdício de banda.

Nesse trabalho, investigamos os padrões de compartilhamento entre usuários do Dropbox localizados em um mesmo domínio buscando responder às seguintes questões: O volume de tráfego gerado pelo download de conteúdo compartilhado por usuários locais ao domínio é significativo? É possível reduzir o desperdício de banda associado a esse tráfego de forma efetiva e eficaz com o uso de caching? Apesar dos estudos sobre padrões de carga e tráfego do Dropbox [5], [6], essas questões ainda não foram abordadas.

Para tal, primeiramente caracterizamos os padrões de compartilhamento entre usuários do Dropbox em um grande campus universitário, a partir de dados de tráfego coletados durante quatro meses. Nesse ambiente, o Dropbox representa um grande volume de dados [7]. A partir dessa caracterização, desenvolvemos e validamos um gerador de cargas sintéticas capaz de capturar, de forma realista, o comportamento dos compartilhamentos pelos usuários locais no Dropbox. Por fim, propomos uma mudança na arquitetura do protocolo de sincronização do Dropbox que considera a inclusão de *caches* locais ao domínio para armazenar as atualizações feitas pelos usuários.

Nossos resultados indicam que o volume de dados compartilhados entre os usuários do campus via Dropbox é razoavelmente alto: cerca de 24% de todo o tráfego de *download* gerado pelo Dropbox está associado ao compartilhamento de conteúdo entre 2 ou mais usuários. Mais ainda, mostramos (via simulação) que a nossa proposta de arquitetura de *cache* pode reduzir o desperdício de banda. As simulações, conduzidas a partir de cargas sintéticas providas pelo nosso gerador, mostram que, mesmo com um cache pequeno, seria possível evitar praticamente todos os *downloads* redundantes ocasionados por compartilhamentos locais. Por exemplo, um *cache* de apenas 100 GB, em um cenário de carga alta, resultaria em aproximadamente 93% de redução no volume de *downloads* em compartilhamentos (i.e., *byte hit ratio*). Tal redução, que se reflete em economia de banda na(s) rede(s) entre os servidores de armazenamento e o ponto de entrada da rede universitária, beneficiaria tanto o provedor do serviço de armazenamento (Dropbox) e seus usuários, quanto a Internet como um todo.

Em suma, as principais contribuições deste artigo são: (1) a primeira caracterização dos padrões de compartilhamento entre usuários de um mesmo domínio; (2) um gerador de cargas sintéticas que captura, de maneira realista, os padrões de compartilhamento e atualização de conteúdo por usuários do Dropbox em um campus universitário; e (3) a proposta e a avaliação de uma mudança na arquitetura do protocolo do Dropbox, que considera a inclusão de *caches* locais ao domínio, resultando em considerável economia de banda. Ressaltamos que o gerador desenvolvido será disponibilizado como software livre e é, portanto, uma ferramenta útil para avaliações do Dropbox e/ou de modificações da sua arquitetura em outros cenários.

A seguir, a Seção II discute trabalhos relacionados. A Seção III apresenta conceitos básicos do Dropbox e a metodologia adotada para coleta e análise de dados. A Seção IV discute resultados da caracterização dos compartilhamentos, bem como o gerador de cargas sintéticas desenvolvido. Nossa proposta de arquitetura de sincronização e *caching* é detalhada na Seção V. Por fim, a Seção VI sumariza o artigo.

## II. TRABALHOS RELACIONADOS

Este trabalho é pioneiro por avaliar o impacto, no tráfego de uma rede particular (especificamente, uma rede universitária), do compartilhamento de conteúdo por meio de clientes de armazenamento nas nuvens. O trabalho de [5] avalia alguns aspectos do compartilhamento entre usuários do Dropbox usando uma coleta de dados de voluntários.

<sup>&</sup>lt;sup>2</sup>https://www.dropbox.com/pt\_BR/help/137

Nosso trabalho, ao invés disso, estuda os compartilhamentos a partir de informações do protocolo de controle do Dropbox obtidas por medições passivas. Isso nos permite apresentar uma análise mais abrangente tanto em termos do tamanho da amostra (i.e., cobrindo a população *completa* de uma rede acadêmica), quanto da duração da amostra (i.e., cobrindo vários meses).

A caracterização feita neste trabalho e a construção do nosso gerador de cargas sintéticas tomam como base resultados de [3], que apresenta uma caracterização do tráfego do Dropbox a partir de medidas passivas, e de [6], que propõem um modelo para o funcionamento do cliente Dropbox. Diferentemente desses trabalhos, nós caracterizamos os padrões de compartilhamento no Dropbox, desenvolvemos um gerador de cargas sintéticas, e propomos uma arquitetura de sincronização para auxiliar o serviço de armazenamento na nuvem.

Alguns trabalhos [8], [9] também analisam o tráfego de ferramentas de armazenamento nas nuvens, como o Dropbox ou o Wuala, a partir de medições de tráfego na rede. As características dos arquivos armazenados em serviços similares ao Dropbox e os possíveis gargalos em seus protocolos são estudados por [1], [10]. Nenhum desses trabalhos, porém, discute o impacto de compartilhamentos no tráfego dos serviços.

A Qualidade de Experiência (QoE) de serviços de armazenamento foi estudada por [11], [12]. Diversos aspectos técnicos como a largura de banda disponível e o tempo de sincronização são identificados como parâmetros importantes para a satisfação dos usuários. Nosso trabalho propõe um gerador de cargas sintéticas realistas que pode ser usado para quantificar o impacto de mudanças em protocolos e clientes de armazenamento na QoE. Além disso, propomos e validamos uma mudança na arquitetura do protocolo de sincronização do Dropbox, que mostramos ter potencial para reduzir o tráfego em redes com alto grau de compartilhamento (e.g., campi universitários) – logo, com provável impacto positivo na QoE percebida pelos usuários.

Por fim, alguns trabalhos comparam o desempenho de ferramentas [4], [13], [2], serviços e provedores [14] de armazenameno na nuvem. Nosso trabalho trata de desempenho sob uma perspectiva diferente. Nós analisamos uma característica importante desses serviços, i.e., o compartilhamento de arquivos, visando uma melhoria de desempenho, a partir da diminuição do desperdício de banda com *downloads* redundantes.

#### III. CONCEITOS E METODOLOGIA DE COLETA DE DADOS

#### A. Dropbox: Visão Geral

Cada usuário do Dropbox tem um repositório associado à sua conta. Esse repositório é composto minimamente por uma pasta raiz, onde o usuário pode armazenar arquivos ou criar subpastas. A aplicação também oferece ao usuário a funcionalidade de compartilhar arquivos. Para tal, o usuário pode configurar uma ou mais pasta(s) compartilhada(s) em seu repositório e convidar outros usuários a terem acesso ao seu conteúdo. Usuários convidados recebem notificações por e-mail. Caso aceitem o convite, eles terão a pasta compartilhada adicionada aos seus dispositivos, podendo então fazer atualizações. Tecnicamente, o Dropbox identifica tanto pastas compartilhadas quanto pastas raiz da mesma maneira – pastas compartilhadas simplesmente aparecerem no dispositivo de vários usuários. Por esse motivo, utilizamos os termos pasta, pasta raiz e pasta compartilhada sem nenhuma distinção neste trabalho.

A arquitetura do Drobpox apresenta dois componentes principais: (1) servidores de controle, que são gerenciados pelo Dropbox em sua infraestrutura privada; e (2) servidores de armazenamento, que são hospedados na Amazon. Os arquivos de usuários são sempre armazenados na nuvem pública da Amazon. Tanto para servidores de controle quanto de armazenamento, subdomínios de dropbox.com são usados para identificar os diferentes componentes do serviço e as funcionalidades específicas do cliente Dropbox [6], [3].

Quando iniciado, o cliente Dropbox se registra em um servidor de controle e requisita a lista de atualizações no repositório do usuário. Em seguida, o cliente faz o *upload/download* dessas atualizações para/de os servidores de armazenamento. Toda comunicação para autenticação e troca de dados é criptografada [3]. Porém, o cliente mantém uma conexão TCP com um servidor de controle, na qual mensagens não-criptografadas do sistema de arquivos do Dropbox são trocadas, informando o estado de cada pasta compartilhada no dispositivo do usuário. O cliente Dropbox troca mensagens (via protocolo HTTP) com servidores de controle a uma taxa aproximada de 1 requisição por minuto. Essas mensagens são cruciais para o nosso trabalho como descrito a seguir, por conter informações atualizadas do estado do repositório do usuário e da versão atual de cada pasta compartilhada pelos usuários.

## B. Coleta de Dados

Nós coletamos traços de dados de tráfego da rede de um campus universitário no Brasil com cerca de 57 mil pessoas, que inclui tráfego gerado por laboratórios e escritórios de administração, conforme a metodologia proposta em [3]. A ferramenta tstat [15] foi usada para coletar informações sobre as conexões TCP nessa rede e as requisições HTTP direcionadas aos servidores do Dropbox. Foram utilizadas as mesmas heurísticas de [3] para identificar e classificar o tráfego Dropbox. Por exemplo, para classificar o tráfego entre diferentes funcionalidades do Dropbox (i.e., controle e armazenamento de dados), procuramos por textos como \*.dropbox.com nos certificados TLS/SSL ou no domínio que os clientes requisitaram aos servidores DNS. Como resultado desta etapa, obtivemos uma base de

Tabela I Sumário do tráfego Dropbox processado dos traços da rede.

Período	24/03-31/07/14
Volume Upload (TB)	1.97
Volume Download (TB)	4.39
Número de usuários	6478
Número de usuários que compartilham pastas	3445
Número de pastas	16485
Número de pastas compartilhadas localmente	3233
Número de notificações de modificação em pastas	3160095

dados contendo informações sobre cada conexão TCP direcionada ao Dropbox, incluindo a funcionalidade provida pelo servidor específico contactado pelo cliente.

Diferentemente das coletas feitas em [3], [6], nossa coleta inclui todas as mensagens de controle do sistema de arquivo do Dropbox transferidas em conexões não-criptografadas. Essas mensagens de controle incluem: (1) o endereço IP anonimizado do dispositivo conectado ao Dropbox; (2) um identificador único do dispositivo; (3) um código numérico associado ao usuário; (4) um identificador único de cada pasta compartilhada disponível no dispositivo; e, finalmente, (5) um identificador da versão atual de cada pasta compartilhada no dispositivo<sup>3</sup>. Importante para a nossa análise, o número da versão de cada pasta compartilhada é um inteiro crescente, o que nos permite monitorar a evolução das pastas ao longo tempo.

Dessas informações de controle do Dropbox, podemos identificar eventos de modificações em pastas compartilhadas, como o aparecimento e o desaparecimento de compartilhamentos, ou a alteração de arquivos. Para cada um desses eventos, os servidores Dropbox anunciam um novo número de versão da pasta para todos os dispositivos participantes do compartilhamento, que contactam servidores de dados do Dropbox para obter as alterações. Como as transferências de dados são criptografadas, registramos apenas (1) o endereço IP anonimizado do dispositivo; (2) os instantes de tempo inicial e final; e (3) o volume de dados transferido. Por fim, analisando o volume de dados, podemos imediatamente identificar se o usuário criou um novo conteúdo (i.e., houve um *upload*) ou se ele recebeu modificações executadas em outro dispositivo (i.e., houve um *download*).

Portanto, extraímos dos traços coletados: (1) as notificações de modificações nas pastas (mensagens de controle); e (2) informações sobre as transferência de dados (mensagens de dados). Dado que essas informações são coletadas de forma independente e não contem um identificador único comum (e.g., o identificador do dispositivo), propomos um método para associar as notificações aos dados transferidos. Por meio de experimentos em ambiente controlado, primeiramente, observamos que o cliente emite notificações imediatamente após modificar uma pasta (*upload*) ou antes de receber uma modificação (*download*). A seguir, medimos o tempo decorrido entre transferências de dados e notificações mais próximas, ambas pertencentes ao mesmo endereço IP nos traços de dados. Observamos que a distribuição desse tempo apresenta um ponto de inflexão por volta de 10 segundos. Logo, adotamos esse limiar para realizar a associação de notificações aos dados transferidos. As transferências que ocorreram em um intervalo de tempo para as notificações mais próximas, superior a esse limiar, foram descartadas, pois podem levar a associações errôneas. Analisamos o impacto dos descartes na próxima seção.

A Tabela I sumariza os dados coletados, apresentando o período da coleta, o volume de tráfego e os números totais de usuários, pastas e modificações observados. Mostramos na tabela o número de pastas que são compartilhadas por vários usuários locais, assim como o número de usuários (locais) que compartilham essas pastas. Note que eventuais compartilhamentos com usuários externos à rede monitorada não são contabilizados nas estatísticas de pastas compartilhadas da Tabela I. Também são descartadas notificações feitas em pastas diferentes por usuários diferentes sob um mesmo NAT, desde que as mesmas ocorram em um intervalo de ate 10 segundos. Tais notificações representam apenas 1% dos dados.

## IV. AVALIAÇÃO DOS COMPARTILHAMENTOS NO DROPBOX

Esta seção discute os padrões de compartilhamento de conteúdo no Dropbox. Avaliamos o volume dos dados nos compartilhamentos (Seção IV-A); caracterizamos os seus padrões específicos (Seção IV-B); e apresentamos o nosso gerador de cargas sintéticas (Seção IV-C).

<sup>3</sup>Nossa coleta não inclui nenhuma informação que possa revelar a identidade dos usuários, bem como informações pessoais ou dos arquivos armazenados no Dropbox.

Tabela II
ESTIMATIVAS DOS VOLUMES DE UPLOAD E DOWNLOAD (GB) PARA TODAS AS PASTAS E PARA AS PASTAS COMPARTILHADAS LOCALMENTE PARA
DIFERENTES LIMIARES.

	limiar de 10 seg.	limiar de 60 seg.	limiar de 600 seg.
Upload	871,07 (43%)	1201,88 (59,5%)	1518,08 (75%)
Download	942,12 (21%)	1333,17 (29,7%)	2021,59 (45%)
Upload (compartilhadas)	85,59 (9,8%)	117,26 (9,7%)	142,73 (9,4%)
Download (compartilhadas)	222,24 (23,6%)	326,23 (24,5%)	493,45(24,4%)

#### A. Compartilhamento de Conteúdo por Usuários do Campus Universitário

Conforme mostrado na Tabela I (Seção III), 53% dos usuários do campus participam de pelo menos uma pasta compartilhada. Mais ainda, aproximadamente 20% das pastas são compartilhadas por pelo menos dois usuários do campus. A Tabela II mostra os volumes de dados transferidos na rede para todas as pastas observadas. Esses números foram computados após realizar as associações de transferências de dados às notificações, seguindo o limiar de 10 segundos (Seção III). Adicionalmente, também incluimos resultados para limiares de 60 e 600 segundos visando analisar o descarte de dados.

Ao lado de cada volume, indicamos a sua porcentagem em relação a um volume total de referência. As referências para os volumes de *upload* e *download* estimados para todas as pastas (linhas 2 e 3 da tabela) são os volumes totais correspondentes observados nos traços *antes* da associação de transferências de dados para notificações. Essas porcentagens nos permitem avaliar o impacto do limiar no descarte de dados. A referência para os volumes de *upload* e *download* estimados para as pastas compartilhadas (linhas 4 e 5 da tabela) são os volumes estimados nas linhas 2 e 3 da Tabela II respectivamente.

A Tabela II mostra que limiares maiores que 10 segundos aumentam a porcentagem de transferências associadas a notificações para todas as pastas (i.e., menor descarte). No entanto, o foco deste trabalho está principalmente no volume de *download* para pastas compartilhadas. Observamos que o valor de limiar tem impacto mínimo na *porcentagem* de *downloads* para pastas compartilhadas, que se mantém em torno de 24% para o período da coleta. Esse volume de dados pode representar um desperdício de banda, já que grande parte desse conteúdo poderia estar replicado localmente no campus. Assim, tão logo um usuário fosse realizar uma atualização, ele o faria sem recorrer aos servidores do Dropbox.

O recurso de LAN Sync, adotado pelo Dropbox para sincronizar arquivos entre dispositivos e pastas compartilhadas na mesma rede local, deveria tomar proveito do grande volume de pastas compartilhadas no campus. Entretanto, a maioria das pastas compartilhadas na universidade contém usuários em sub-redes diferentes. De fato, do total de 3233 pastas compartilhadas (Tabela I), apenas 18% delas têm todos seus usuários na mesma sub-rede<sup>4</sup>.

## B. Caracterização dos Padrões de Compartilhamento

Para entender os padrões de compartilhamento de pastas no Dropbox, nós primeiro analisamos o tempo em que uma pasta permanece ativa no sistema. Intuitivamente, uma pasta é criada e possivelmente compartilhada com um ou mais usuários. Esses usuários realizam várias modificações no conteúdo da pasta nos dias iniciais de sua existência. Com o passar do tempo, esse interesse diminui, até que a pasta torna-se inativa, não recebendo mais modificações. A Figura 1(a) apresenta a distribuição acumulada do número de dias desde a criação de uma pasta até que a mesma tenha recebido X% de todas as modificações observadas em nossos dados, para X igual a 70%, 80%, 90% e 100%. Essas distribuições foram computadas considerando apenas pastas observadas nos traços da rede por pelo menos 60 dias. Note que cerca de 16% das pastas têm todas as modificações observadas em apenas um dia, enquanto praticamente 50% das pastas recebem todas as modificações em um período inferior a 30 dias. Estes números indicam que muitas pastas recebem rajadas de modificações em curtos períodos de tempo. De fato, a figura mostra que cerca de 45% das pastas recebem 70% de todas as suas modificações apenas no primeiro dia de existência.

A seguir, nós caracterizamos os padrões de modificações em pastas compartilhadas, focando em: número de usuários locais associados a cada pasta, tempo entre modificações sucessivas de uma mesma pasta e volume de dados transferidos por modificação. Para cada variável analisada, nós apresentamos a distribuição estatística que melhor se adequa aos dados, escolhida entre vários modelos usados na literatura. Para cada modelo, os parâmetros da distribuição que mais se aproxima dos dados são determinados usando o método de estimativa por máxima verossimilhança. Após definição dos parâmetros, a distribuição com menor distância de Kolmogorov-Smirnov (contínua) ou menor erro quadrático mínimo (LSE) (discreta) em relação aos dados foi escolhida [16].

<sup>&</sup>lt;sup>4</sup>A rede da universidade é tipicamente dividida em sub-redes definidas por prefixos /24.

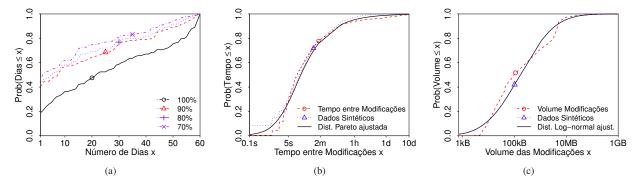


Figura 1. Modificações em Pastas: (a) Tempo até X% das modificações (X=70-100%); (b) Tempo entre modificações: distribuição Pareto com  $\alpha$ =0,460, $\kappa$ =4,832 (em seg.); (c) Volume de dados por modificação: distribuição LogNormal com  $\mu$  =5,091 e  $\sigma$ =2,442 (em kB).

Como mostrado na Tabela I, cerca de 20% das pastas são compartilhadas por múltiplos usuários locais. Dessas pastas, 13% são compartilhadas por 2 usuários, enquanto na média, o número de usuários locais que compartilham uma mesma pasta é 2,8, e menos de 2% das pastas têm mais de 5 usuários associadas a elas. A distribuição do número de usuários locais associados a cada pasta, omitida por restrições de espaço, foi bem aproximada por uma distribuição Binomial Negativa $^5$  com parâmetros r=0.225 e p=0.384 e adicionando 1 a cada número aleatório gerado por ela.

As pastas armazenadas no Dropbox tendem a sofrer modificações consecutivas em curtos intervalos de tempo. A Figura 1(b) mostra a distribuição acumulada computada sobre todos os intervalos entre modificações em uma mesma pasta, para todas as pastas. Mais de 70% das modificações ocorrem em intervalos inferiores a 1 minuto, embora alguns intervalos superem 1 dia. Esta distribuição enviesada para valores pequenos, que, conforme mostrado na figura, é bem ajustada por uma distribuição Pareto<sup>6</sup>, reflete as rajadas de modificações mencionadas anteriormente.

A última variável analisada é o volume de dados associado a cada modificação, cuja distribuição acumulada, computada sobre todas as modificações de todas as pastas, é mostrada na Figura 1(c). Observa-se que as modificações tendem a gerar um tráfego pequeno: cerca de 40% das modificações correspondem a menos de 100 kB, enquanto, na média, cada modificação corresponde a 3 MB. Uma distribuição Log-Normal<sup>7</sup> modela bem o tamanho das modificações de pastas compartilhadas. As curvas "dados sintéticos", nas Figuras 1(b) e 1(c), serão discutidas na próxima seção.

## C. Gerador de Cargas Sintéticas

Nós desenvolvemos um gerador de cargas sintéticas baseado nos eventos de modificações em pastas caracterizados na Seção IV-B. Esse gerador tem por objetivo produzir um traço de modificações em um dado número n de pastas do Dropbox compartilhadas pelos usuários de um domínio durante um intervalo de tempo  $(0 \cdots t_{max})$ . Com esse traço, ele visa capturar os volumes de dados transmitidos na rede ao longo do tempo à medida em que um usuário modifica uma pasta (upload) e os demais usuários locais que compartilham a mesma pasta obtêem essa modificação (download).

Para tal, o gerador modela vários componentes de carga utilizando as distribuições estatísticas que melhor se adequam a eles em dados *reais*. Em particular, ele utiliza as distribuições do número de usuários locais por pasta, tempo entre modificações de uma pasta e volume de dados por modificação discutidos na Seção IV-B. Note que usuários que compartilham uma mesma pasta podem ou não estar conectados ao Dropbox (*online*) quando uma modificação é feita. Assim, como em [6], modelamos o comportamento dinâmico de cada usuário do Dropbox a partir das distribuições de duração de sessão (tempo *online*) e tempo entre sessões. Adotamos distribuições Weibull e LogNormal para essas duas variáveis, como apresentado em [6].

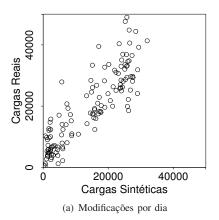
O funcionamento do gerador consiste em, inicialmente, associar a cada pasta os usuários (locais) que a compartilham. Isto é feito utilizando a distribuição Binomial Negativa caracterizada na seção anterior para gerar um número de usuários para cada pasta<sup>8</sup>. Um número de usuários igual a 1 implica que a pasta não é compartilhada com nenhum outro usuário local, embora possa ser compartilhada com usuários externos.

```
^5 Distribuição de probabilidade de massa (PMF) da Binomial Negativa: p_X(x) = \frac{\Gamma(x+r)}{\Gamma(r)x!}p^r(1-p)^x .
```

<sup>&</sup>lt;sup>6</sup>PDF da distribuição Pareto:  $p_X(x) = \frac{\alpha \kappa^{\alpha}}{(x+\kappa)^{\alpha+1}}$ . Note que esta é uma distribuição Pareto tipo II.

<sup>&</sup>lt;sup>7</sup>PDF da distribuição Log-Normal:  $p_X(x) = \frac{1}{x\sigma\sqrt{2\pi}}e^{\frac{-(\ln(x)-\mu)^2}{2\sigma^2}}$ .

<sup>&</sup>lt;sup>8</sup>Esta estratégia trata os usuários de cada pasta de forma independente. Alternativamente, também consideramos extrair os usuários associados a cada pasta dos traços reais, preservando assim o número de pastas por usuário. Embora menos realista, a abordagem adotada é mais simples e geral. Além disto, não observamos diferenças significativas entre os traços sintéticos produzidos pelas duas abordagens.



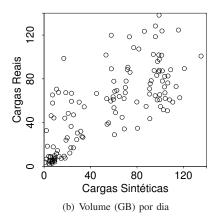


Figura 2. Validação do Gerador de Cargas Sintéticas.

Para cada usuário, o gerador simula sucessivas sessões utilizando as distribuição de duração de sessão e tempo entre sessões. Ele também simula, para cada pasta, uma sequência de modificações por usuários locais utilizando as distribuições dos tempos entre modificações e de volume de dados por modificação. Para cada modificação, o gerador contabiliza os volume de *upload* e, no caso de pastas compartilhadas por múltiplos usuários, escalona operações de *download* para cada usuário associado à pasta (exceto o que gerou a modificação). Caso o usuário esteja com uma sessão aberta no instante em que a modificação foi feita, o *download* é feito imediatamente. Caso contrário, ele é escalonado assim que o usuário iniciar uma nova sessão.

Como o foco do gerador é no cálculo do volume agregado de *download* e *upload* por pasta, a escolha do usuário que faz cada modificação é menos importante do que *quando* a modificação é feita. Assim, para fins de geração das cargas sintéticas, nós consideramos que toda pasta será modificada por algum usuário (escritor) com sessão aberta no instante da modificação. Como trabalho futuro, consideramos estender o gerador para capturar o tráfego sob a perspectiva de cada usuário. Neste caso, a escolha do usuário para cada operação (*upload* e *download*) deve ser modelada de forma mais detalhada.

Nós validamos o gerador de duas maneiras. Primeiramente, nós avaliamos que as distribuições das variáveis modeladas extraídas dos traços sintéticos se aproximam das distribuições correspondentes dos dados reais. As distribuições dos dados sintéticos para o tempo entre as modificações sucessivas de uma mesma pasta e o volume dessas modificações são mostradas ns Figuras 1(b) e 1(c) (Seção IV-B): observamos que as distribuições de dados reais e sintéticos são bastante similares. Resultados semelhantes foram obtidos para o número de usuários por pasta. Esta validação pode ser considerada um teste de sanidade já que as distribuições analisadas são entradas do gerador.

Uma validação mais interessante foca em métricas indiretas, que não são explicitamente modeladas pelo gerador. Para realizar tal validação, considerou-se o número e o volume (*upload* e *download*) de modificações ocorridas diariamente nos traços coletados. O gerador produziu um traço sintético para cada dia *d* utilizando as mesmas distribuições mencionadas acima, mas tendo como alvo o número de pastas observados no traço real naquele dia. Assim podemos comparar os valores das duas métricas em traços reais e sintéticos para cada dia.

Esses valores são mostrados nas Figuras 2(a) e 2(b), onde cada ponto representa um dia. Idealmente, o gráfico deveria apresentar os pontos próximos à reta de 45°. Entretanto, isto é muito difícil de se alcançar, principalmente quando o processo sendo modelado é complexo, como no caso dos compartilhamentos no Dropbox. Entretanto, pode-se verificar que o gerador é capaz de capturar as principais tendências dos dados reais já que as correlações lineares entre dados sintéticos e reais são bem altas: 0,87 e 0,74 para número e volume de modificações respectivamente.

A Figura 2(a) mostra que o gerador subestima o número de modificações em muitos dias possivelmente devido aos casos em que as modificações das pastas ocorrem quando usuários associados a ela não estão com sessões abertas. Uma modelagem mais precisa desse processo, incluindo a rede de compartilhamentos [5], é bastante desafiadora, sendo deixada para trabalhos futuros. A despeito desta imprecisão, a Figura 2(b) mostra que o gerador tende a superestimar o volume gerado, o que é razoável uma vez que, para o planejamento de capacidade dos servidores de armazenamento ou da capacidade da rede, tais superestimativas levam a decisões mais conservadoras.

Em suma, apesar das imprecisões, consideramos que o gerador captura de forma bastante razoável os padrões de compartilhamento de pastas, principalmente considerando a complexidade do processo modelado. Ele é uma ferramenta bastante útil para suportar avaliações de modificações no protocolo do Dropbox, como a discutida na próxima seção.

#### V. Nova Arquitetura de Sincronização

Esta seção apresenta e avalia a nossa proposta de modificação na arquitetura de sincronização do Dropbox para reduzir o desperdício de banda devido a *downloads* nos compartilhamentos por usuários locais a um mesmo domínio.

### A. Descrição da Arquitetura Proposta

A Figura 3(a) apresenta a arquitetura atual do Dropbox, na qual as modificações nas pastas são armazenadas nos servidores remotos. A figura também ilustra o uso de LAN Sync, que permite que modificações de pastas compartilhadas por usuários de uma mesma rede local sejam feitas diretamente entre eles. A nova arquitetura proposta na Figura 3(b) considera a inclusão de um *cache* para armazenar dentro de cada domínio de rede (e.g., um campus ou uma empresa) as modificações de pastas de usuários daquele domínio.

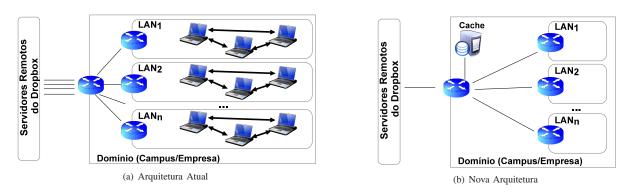


Figura 3. Arquiteturas de Sincronização do Dropbox.

Nossa proposta pressupõe que o Dropbox forneça o serviço especial de *cache* para universidades ou grandes empresas onde muitos usuários utilizam o cliente Dropbox. A universidade ou empresa interessada na implementação do serviço deve fornecer a infraestrutura necessária (i.e., um servidor) para a instalação e funcionamento do mesmo.

O serviço de *cache* funcionaria da seguinte forma. Qualquer modificação feita por um usuário local é armazenada primeiramente no *cache* e posteriormente enviada aos servidores de armazenamento e controle do Dropbox (vide Seção III). Em seguida, o Dropbox notifica essa modificação para todos os clientes de usuários que compartilham a pasta. Ao receber uma notificação, o cliente primeiramente busca a modificação no *cache* local. Se a modificação estiver armazenada no *cache*, ocorre um acerto (*hit*), caso contrário uma falta (*miss*). Na ocorrência de uma falta, o serviço de cache busca a modificação no Dropbox e a armazena no *cache* para servi-la ao cliente requisitante e a outras possíveis futuras requisições. Contemplamos duas configurações de *cache* em função de quais modificações são armazenadas nele: todas modificações e somente modificações em pastas compartilhadas por múltiplos usuários locais. A primeira configuração é bem mais simples de ser implementada, pois todas as modificações são tratadas indistintamente. A segunda configuração exige uma implementação mais sofisticada, mas pode reduzir a necessidade de espaço de *cache*. Como política de substituição de modificações no *cache*, usamos LRU *Least Recently Used*<sup>9</sup> que é uma política considerada eficiente e frequentemente usada em vários tipos de *cache*. Note que cada modificação de pasta pode ser identificada por um número de versão, o que permite o gerenciamento adequado do conteúdo no *cache*.

## B. Avaliação

Os benefícios da arquitetura proposta foram avaliados via simulação em cenários construídos utilizando o nosso gerador de cargas sintéticas. Esta avaliação considerou tanto a redução no tráfego de *download* de modificações de pastas compartilhadas por usuários do domínio alvo, quanto o custo do *cache*. A redução no tráfego foi quantificada pelo volume de dados transferidos do cache (*byte hit ratio*), enquanto o custo foi estimado pelo tamanho do *cache*. Note que, conforme discutido na Seção IV-A, a redução máxima de tráfego para os nossos dados, alcançada quando o *byte hit ratio* é 100%, está limitada a 24% do tráfego total de *downloads* (i.e., *downloads* de pastas compartilhadas).

A Figura 4 mostra o *byte hit ratio* para vários tamanhos do cache em três cenários: (1) uma carga de 1065 pastas modificadas por dia, o que corresponde à carga média observada em nossos traços, (2) uma carga de 2185 pastas, que representa o maior número de pastas observadas diariamente em nossos traços, e (3) uma carga bem mais alta com 4000 pastas. Para cada um desses cenários, avaliamos as duas configurações de *cache* mencionadas na seção anterior. A curva preta contínua mostra os resultados quando o *cache* armazena todas as modificações de pastas feitas, independentemente

<sup>&</sup>lt;sup>9</sup>A avaliação de diferentes políticas está fora do escopo deste trabalho.

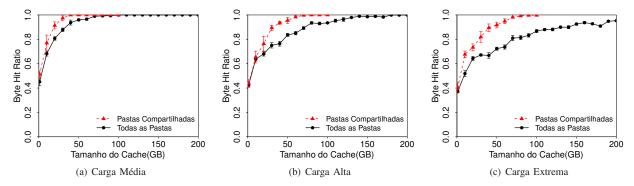


Figura 4. Benefícios da Arquitetura de Cache Proposta: armazenando modificações de todas as pastas ou apenas pastas compartilhadas localmente.

do número de usuários locais que compartilham a pasta<sup>10</sup>. A curva vermelha tracejada mostra os resultados quando o *cache* armazena apenas modificações de pastas compartilhadas por múltiplos usuários locais. Cada resultado na figura corresponde a uma média de 10 replicações, com o intervalo de 95% de confiança correspondente.

Note que um *cache* com apenas 1GB leva a um *byte hit ratio* de 40% nos 3 cenários. Mais ainda, considerando a configuração de *cache* mais simples que armazena todas as modificações, um *cache* com 100GB resulta em um *byte hit ratio* superior a 93% nos cenários de carga média e alta e igual a 87% no cenário com carga mais alta. Isto corresponde a quase o máximo possível de redução de *downloads* dos servidores remotos do Dropbox, particularmente nos dois primeiros cenários. Também podemos notar que o aumento no *byte hit ratio* (e consequente redução de tráfego) para tamanhos de *cache* maiores que 150 GB é próximo de zero para os três cenários. Logo, o uso de *caches* maiores que esse tamanho traz poucos benefícios para domínios cujos padrões de tráfego Dropbox seguem os cenários analisados.

A segunda configuração de *cache* avaliada, que armazena somente modificações de pastas compartilhadas por múltiplos usuários locais, é ainda mais eficiente: um *cache* com somente 50 GB é suficiente para atingir *byte hit ratios* superiores a 95% nos dois primeiros cenários, e igual a 90% no terceiro cenário. Entretanto, ela tem uma complexidade de implementação maior, uma vez que as modificações de pastas devem ser tratadas de forma diferente, dependendo se a pasta é compartilhada localmente ou não. Isto pode refletir em um número maior de mensagens de controle entre servidores remotos, *cache* e usuários. Esta maior complexidade pode não compensar a redução de espaço alcançada, principalmente considerando o baixo custo de memória atualmente.

Em suma, observamos que a arquitetura proposta, mesmo com um *cache* razoavelmente pequeno, resulta em uma considerável diminuição do tráfego entre o domínio analisado (campus universitário) e o Dropbox. Esta redução beneficia não somente o Dropbox mas também os usuários finais, que potencialmente têm uma qualidade de serviço superior dado que o retardo para obtenção dos dados poderá ser bem menor. Mais ainda, ela beneficia a Internet como um todo, com a redução do tráfego nos pontos centrais da rede.

### VI. CONCLUSÕES E TRABALHOS FUTUROS

Este artigo apresentou a primeira caracterização dos padrões de compartilhamento no Dropbox entre usuários de um mesmo domínio, um campus universitário. Esta análise revelou que existe um potencial de economia de banda significativa com a redução de tráfego de dados repetidos e motivou a proposição de uma modificação na arquitetura do Dropbox que inclui *caches* para armazenar modificações nas pastas compartilhadas localmente. Os resultados da caracterização foram usados no desenvolvimento de um gerador de cargas sintéticas que permite a avaliação de modificações no protocolo do Dropbox. Em particular, usamos o gerador para avaliar os benefícios da nova arquitetura proposta em diferentes cenários, concluindo que mesmo *caches* pequenos (e.g., 100GB) permitem um economia de banda bem próxima da máxima possível.

Trabalhos futuros incluem refinamentos no gerador para incluir outros aspectos (e.g., a rede de compartilhamento entre usuários e a criação de novas pastas) e a análise dos custos para implantação de arquiteturas alternativas, como a que foi proposta neste trabalho, que contribuam para a economia de banda.

## REFERÊNCIAS

- [1] Z. Li, C. Jin, T. Xu, C. Wilson, Y. Liu, L. Cheng, Y. Liu, Y. Dai, and Z.-L. Zhang, "Towards Network-Level Efficiency for Cloud Storage Services," in *Proc. IMC*, 2014.
- [2] R. Gracia-Tinedo, M. S. Artigas, A. Moreno-Martinez, C. Cotes, and P. G. Lopez, "Actively Measuring Personal Cloud Storage," in *Proc. IEEE CLOUD*, 2013.

<sup>10</sup> Dada a operação do gerador de cargas, somente modificações feitas por usuários locais ao domínio são incluídas nas cargas sintéticas avaliadas. Em um cenário real, modificações feitas por usuários externos também poderiam ser armazenadas no cache.

- [3] I. Drago, M. Mellia, M. M. Munafò, A. Sperotto, R. Sadre, and A. Pras, "Inside Dropbox: Understanding Personal Cloud Storage Services," in *Proc. IMC*, 2012.
- [4] I. Drago, E. Bocchi, M. Mellia, H. Slatman, and A. Pras, "Benchmarking Personal Cloud Storage," in Proc. IMC, 2013.
- [5] E. Costa, L. Costa, I. Drago, A. Vieira, A. Ziviani, A. P. C. da Silva, and J. M. de Almeida, "Análise da Topologia Social do Dropbox," in *Anais do WP2P+*, 2014.
- [6] G. Gonçalves, I. Drago, A. P. C. da Silva, J. M. de Almeida, and A. Vieira, "Caracterização e Modelagem da Carga de Trabalho do Dropbox," in *Anais do SBRC*, 2014.
- [7] R. Duarte, I. Cunha, J. Almeida, and A. B. Vieira, "Impact of Provider Failures on the Traffic at a University Campus." in *Proc. IFIP Network*, 2015.
- [8] T. Mager, E. Biersack, and P. Michiardi, "A Measurement Study of the Wuala On-line Storage Service," in Proc. P2P, 2012.
- [9] H. Wang, R. Shea, F. Wang, and J. Liu, "On the Impact of Virtualization on Dropbox-Like Cloud File Storage/Synchronization Services," in *Proc. IWOoS*, 2012.
- [10] S. Liu, X. Huang, H. Fu, and G. Yang, "Understanding Data Characteristics and Access Patterns in a Cloud Storage System," in Proc. CCGrid, 2013.
- [11] P. Amrehn, K. Vandenbroucke, T. Hossfeld, K. D. Moor, M. Hirth, R. Schatz, and P. Casas, "Need for Speed? On Quality of Experience for Cloud-based File Storage Services," in *Proc. PQS*, 2013.
- [12] P. Casas and R. Schatz, "Quality of Experience in Cloud Services: Survey and Measurements," Computer Networks, vol. 68, pp. 149–165, 2014.
- [13] W. Hu, T. Yang, and J. N. Matthews, "The Good, the Bad and the Ugly of Consumer Cloud Storage," SIGOPS Oper. Syst. Rev., vol. 44, no. 3, pp. 110–115, 2010.
- [14] A. Li, X. Yang, S. Kandula, and M. Zhang, "CloudCmp: Comparing Public Cloud Providers," in Proc. IMC, 2010.
- [15] A. Finamore, M. Mellia, M. Meo, M. M. Munafò, and D. Rossi, "Experiences of Internet Traffic Monitoring with Tstat," *IEEE Network*, vol. 25, no. 3, pp. 8–14, 2011.
- [16] W. N. Venables and B. D. Ripley, Modern Applied Statistic with S. Springer, 2002.